

# Classificação de Arritmias Cardíacas utilizando Transformada *Wavelets* e Aprendizado de Máquina por meio de extração de características

Davi Shinji Mota Kawasaki\*, Higor Augusto Bassi Rozan†, João Vitor Bertoncini‡, Vinícius Drago Romano§

\*Engenharia da Computação, Cornélio Procópio/PR 86300-00

Email: kawasaki@alunos.utfpr.edu.br

†Engenharia da Computação, Cornélio Procópio/PR

Email: higorb.rozan@hotmail.com

‡Engenharia da Computação, Cornélio Procópio/PR 86300-000

Email: joaobertoncini@alunos.utfpr.edu.br

§Engenharia da Computação, Cornélio Procópio/PR 86300-000

Email: romano@alunos.utfpr.edu.br

**Abstract**—This work aims to extract and classify ventricular cardiac arrhythmias through *Wavelet Transform* and machine learning algorithms. The article covers a brief theoretical introduction about the medical theme, highlights the extraction window and filter methods, and then train the extracted data through a machine learning software. After that's all covered, it shows the analysis of results with two different types of machine learning algorithms with *WEKA* software.

**Keywords** - Arrhythmias, Feature Extraction, Wavelet Transform, Neural Network, Machine Learning, *WEKA*, *MATLAB*.

## I. INTRODUÇÃO

O ser humano, desde as épocas antigas, tem passado por inúmeras evoluções, assim como também por vários obstáculos pessoais, biológicos e sociais. Os contextos históricos detalham com maestria cada ponto focal característico dentre a história humana milenar, seja pelas conquistas, descobertas, guerras, expansões populacionais e, principalmente, as evoluções e revoluções marcantes.

Nesses contextos sociais, uma "*persona*" sempre esteve presente dentre os momentos históricos humanos, marcando presença principalmente em fatos históricos globais. As enfermidades e doenças produziram significados que iam além das características biológicas - como foi o caso da peste negra -, demonstrando que, além de soluções médicas-científicas, eram necessários investigações socioculturais [1].

Com estimativas da Organização das Nações Unidas (ONU) de que a Terra terá pouco mais de 9 bilhões de habitantes em 2050, a preocupação com enfermidades tem se tornado um tópico cada vez mais alarmante globalmente. De acordo com pesquisas da FAO 1999 e UNICEF 2002, cerca de 18 milhões de seres humanos têm morrido precocemente de doenças curáveis - equivalente a possíveis 50 mil mortes que poderiam ser evitadas diariamente. Além disso, problemas médicos que causam essas doenças aplicam uma grande tensão econômica

principalmente em países subdesenvolvidos, intensificando a pobreza e o nível da população doente [2].

Entre essas várias doenças, as ocasionadas por insuficiências cardíacas e/ou infartos são razões da morte de aproximadamente 17,5 milhões de pessoas por ano no mundo [3]. Segundo a Federação Mundial do Coração (FMC) esses dados demonstram que infartos derivados de problemas cardíacos são uma das principais causas de mortalidade no mundo. A ONG FMC destacou que 80% dessas mortes ocorrem em países com nível de renda médio e baixo [3], caso do Brasil.

O número de infartos e doenças cardíacas vem aumentando devido a alguns fatores gerais, como o sedentarismo, má qualidade da alimentação, estresse, além de outros problemas comuns na cultura de um mundo capitalista globalizado [4].

Para reduzir a quantidade de óbitos consequentes de doenças, profissionais da área da saúde têm investido em ferramentas que possam completar os diagnósticos - sejam de prevenção ou até mesmo emergenciais. Essa antecipação de descoberta de alguma doença - como disfunções cardíacas - podem determinar tratamentos médicos e até mesmo evitar mortes súbitas de pacientes.

Com o crescimento do número de pacientes dentre a volumosa população mundial, cada vez mais métodos automáticos de diagnósticos são necessários para auxiliar os médicos. Um dos caminhos para este diagnóstico, no caso de exames cardiológicos, consiste na utilização do sinal de eletrocardiograma (ECG). A alteração e distúrbios das ondas do ECG podem indicar alterações do ritmo cardíaco, também denominadas como arritmias cardíacas [4], objetivo principal de análise desse artigo. Essas alterações do ritmo cardíaco normalmente são coletadas de forma analógica, ou seja, por análise gráfica visual por profissionais especialistas, o que torna a tarefa extremamente manual e não replicável.

Sob essa análise contextual, esse trabalho propõe formular um algoritmo que seja capaz de detectar, analisar e classificar

automaticamente essas arritmias cardíacas. Conforme a análise literária [4], algoritmos que realizam esse trabalho dificilmente alcançam taxas de 100% de acerto. Para ultrapassar essa barreira, um método será desenvolvido para analisar o sinal de ECG, extrair características relevantes do mesmo e, por fim, classificar cada um dos sinais por dois tipos de Aprendizado de Máquina: Redes Neurais e Árvores de Decisão. Os sinais serão obtidos diretamente da base de dados *MIT-BIH - Arrhythmia Database*, e o foco de classificação dessa base serão sinais de ECG normais ou possuidor de um dos três tipos de arritmias ventriculares: Taquicardia Ventricular (VT), Bigeminismo Ventricular (B) e Trigemismo Ventricular (T).

Por meio da normalização e filtro dos sinais, pretende-se avaliar os resultados através da taxa de confiabilidade do aprendizado de máquina com o *software* WEKA, além de comparar com resultados de outros trabalhos.

O trabalho, portanto, é dividido em: Introdução, Fundamentação Teórica, Metodologia, Extração de Características, Treinamento com Aprendizado de Máquina, Resultados e Discussões, Conclusão.

## II. FUNDAMENTAÇÃO TEÓRICA

### A. Coração

O coração consiste em um órgão localizado atrás da caixa torácica, na parte central do peito entre o pulmão direito e esquerdo [5]. Sua função consiste no batimento ou contração para bombeamento do sangue para todo o corpo por meio de um sistema de vasos sanguíneos [6].

Para realizar o processo de bombeamento de sangue, o coração depende da sua seção direita e esquerda, onde cada uma delas possui duas cavidades: átrio e ventrículo, sendo a primeira superior e a segunda inferior. O fluxo do sangue é realizado por meio de válvulas entre o átrio e o ventrículo, sempre seguindo a direção do primeiro para o segundo.

Por meio dessas válvulas é possível realizar o processamento do oxigênio e do gás carbônico, onde a seção esquerda do coração é responsável pelo envio de sangue com oxigênio para o corpo, enquanto a direita cuida do recebimento do sangue com gás carbônico de diferentes partes do corpo [5]. A cada contração de cada câmara do miocárdio - fluxo de sangue entre o átrio e o ventrículo - acontece o evento chamado de sístole, enquanto no relaxamento ocorre a diástole - processo o qual é repassado para o pulmão para realização da troca de gases [5].

Uma das estruturas internas primordiais para determinar o ritmo do coração chama-se nódulo sinoatrial (SA), ou também chamado de marca-passo. Localizada entre o átrio direito e a veia cava superior (vide Figura 1), ele atua controlando a frequência dos batimentos cardíacos, com cerca de 72 contrações por minuto. Por ter uma frequência alta, seus impulsos se espalham para os átrios e ventrículos, excitando todas as áreas e determinando o ritmo de batimento de quase todo o coração [7].

O coração, por meio do seu batimento, realiza vários eventos cardíacos chamados de ciclos cardíacos, começando pela geração de um potencial de ação propagado pelos átrios




Fig. 1. Representação interna do coração e suas cavidades.

até chegar nos ventrículos. Esse ciclo cardíaco vai conter o relaxamento pela diástole (coração enche de sangue) e a sístole (contração das câmaras de bombeamento). Conforme representado pelos traçados da Figura 2, pode-se visualizar os períodos de pressão (mm Hg), volume (ml), eletrocardiograma e fonocardiograma, sendo o penúltimo a representação gráfica utilizada nesse trabalho para classificação de arritmias.




Fig. 2. Eventos do ciclo cardíaco representados por diferentes traçados no ventrículo esquerdo.

### B. Eletrocardiograma (ECG)

Conforme visualizado no tópico anterior, o nódulo sinoatrial (SA) determina o ritmo do coração por seus impulsos com uma frequência alta. A partir dessa excitação, ocorre paralelamente a propagação de correntes do campo elétrico no músculo cardíaco e nos tecidos das regiões vizinhas, inclusive atingindo a superfície do corpo. Como esse fluxo ocorre entre diversos locais do corpo, pode-se captar diferenças de potenciais por meio de eletrodos na pele, em pontos opostos do coração. Essas medidas podem ser coletadas por meio de 12 derivações clássicas, normalmente se baseando pelo triângulo de Einthoven, representado pela Figura 3.

Por meio de um amplificador, esses potenciais são adquiridos por um período de tempo, em localizações conforme estabelecidas pelas derivações. Esse processo trata-se da eletro-




Fig. 3. Representação do triângulo de Einthoven, com eletrodos sobre os pulsos (RA e LA) e no tornozelo esquerdo (LL).

cardiografia, também conhecida como o exame de eletrocardiograma (ECG), apresentando a excitação cardíaca de forma gráfica para análise patológica por um cardiologista. Esse exame de baixo custo permite a análise de uma cardiopatia/arritmia no momento de ocorrência da mesma, analisando normalmente os segmentos, intervalos e ondas do sinal de ECG.

Um registro de ECG, representado na Figura 4, é representado por meio da voltagem plotada no eixo y pelo tempo no eixo x, onde seu sinal traduz o registro das despolarizações e repolarizações por meio de cinco etapas, representadas pelos formatos de onda P, Q, R, S e T [8].




Fig. 4. Registro de eletrocardiograma com diferentes tipos de intervalos.

Além dos formatos de onda, o ECG apresenta alguns subperíodos que são importantes para uma análise mais detalhada das cardiopatias, como o intervalo entre a onda P e R, o qual representa o tempo de condução do estímulo através do nóculo atrioventricular; e o complexo QRS, que representa a despolarização ventricular. A partir desses subperíodos

pode-se analisar as morfologias do exame, denominadas pela sequência de excitação e recuperação, respectivamente caracterizados pela despolarização e repolarização por meio da diferença de potencial resultante, conforme representado pela Figura 5.




Fig. 5. Sequência de despolarização e repolarização com a representação das ondas e subperíodos.

Estas morfologias permitem a verificação de anormalidades no sistema de condução cardíaca, como as arritmias que vão ser classificadas por meio de aprendizado de máquina nesse trabalho.

### C. Arritmias

Conforme apresentado, os exames de ECG permitem identificar anormalidades no sistema cardiológico, podendo representar diferentes cardiopatias. Elas podem ser sintomaticamente representadas por arritmias cardíacas, que ocorrem por alterações na formação/condução do impulso elétrico através do miocárdio [9]. O ECG é um dos principais exames para estudo e análise das arritmias, justamente porque as mesmas podem modificar a origem/difusão fisiológica do estímulo elétrico, alterando o ritmo cardíaco normal [10].

Dentre os mais diversos tipos de classificação de arritmias, elas podem ser divididas em duas categorias (assintomáticas e sintomáticas) e em dois grupos de frequência: bradicardia - frequência cardíaca menor que 60 batimentos por segundo, e taquicardia - frequência cardíaca maior que 100 batimentos por segundo [7].

O enfoque desse trabalho reside nas arritmias que ocorrem na parte ventricular do batimento cardíaco, como as seguintes: Taquicardia Ventricular (VT), Bigeminismo Ventricular (B) e Trigemismo Ventricular (T).

A taquicardia acontece quando a frequência cardíaca é maior que 100 batimentos por minuto. Ao realizar esforços físicos sua ocorrência é considerada normal, porém após alguns minutos depois do término da atividade física, a frequência cardíaca deve se restabelecer ao nível saudável [4]. Quando isso não acontece ou se em repouso apresenta-se taquicardia, isto pode indicar a existência de alguma patologia, como a taquicardia ventricular representada pela Figura 6.

Já os casos de Bigeminismo e Trigemismo ocorrem por contrações ventriculares prematuras (PVC), onde cada PVC é seguido por uma pausa compensatória que permite que o nóculo sinoatrial descanse no ciclo, conforme representado




Fig. 6. Exemplo de ECG com Taquicardia Ventricular.

na Figura 7. Enquanto no bigeminismo um PVC ocorre em todas as outras batidas de forma constante, o trigeminismo consiste em um PVC ocorrendo somente na terceira batida, onde aparece uma pausa compensatória após essa batida [11].




Fig. 7. Exemplo de ECG com Bigeminismo e Trigeminismo Ventricular.

#### D. Extração do Sinal com Janelamento

O tratamento de sinais normalmente envolve um conjunto grande e finito de dados, os quais devem ser tratados para realização de uma extração e sintetização adequada. Em alguns casos, principalmente envolvendo uma extração de dados com *Transformada Rápida de Fourier (FFT)*, a aquisição pode resultar em sinais com transições abruptas, também conhecidas como descontinuidades [12].

No caso dos ECGs, os sinais possuem vários batimentos no período de 30 minutos da base de dados, onde cada tipo de batimento de arritmia ocorre em alguns momentos específicos pelo sinal. Sendo assim, sabendo cada período específico através de anotações provenientes da base de dados do MIT-BIH, a técnica de janelamento se torna útil, permitindo um enfoque específico da onda completa a ser analisada, além de minimizar possíveis margens de transição como as descontinuidades, reduzindo a perda espectral do sinal [12].

#### E. Processamento do Sinal com Transformadas Wavelets

A *Wavelet* trata-se de uma função que descreve e decompõe outras funções no domínio da frequência, garantindo a análise além do domínio do tempo. A sua decomposição acontece por meio da *Transformada Wavelet*, que trata de uma técnica por dimensão de janela variável, avaliando o sinal no espaço tempo x frequência e os componentes espectrais em um intervalo de tempo [13].

Por trabalhar com janelas, a *Transformada Wavelet* permite que ocorra o translado no tempo se baseando em *Wavelets*-

mãe, a qual se fornece como protótipo para todas as janelas criadas no procedimento de análise do sinal [13].

Por permitir a decomposição do sinal em várias funções no domínio do tempo e frequência, essa transformada possui uma grande abrangência para análise e compreensão de sinais, podendo inclusive ser dividida em contínua e discreta.

Na *Transformada Wavelet Contínua (TWC)* a variável translação representa o deslocamento da janela de amostragem ao longo do tempo, sendo matematicamente definida em  $F(a,b)$ :

$$F(a,b) = \int_{-\infty}^{+\infty} f(t)\Psi_{a,b}dt$$

Cada sinal pode determinar um tipo de *Wavelet*-mãe que pode ser utilizado por uma TWC, como os representados na Figura 8.




Fig. 8. Famílias de TWC: (a) Daubechies; (b) Coiflet; (c) Haar; (d) Symmlet.

A *Transformada Wavelet Discreta (TWD)* permite não perder suas qualidades e propriedades, portando-se de maneira numericamente estável e com uma menor redundância de informação [14]. A sua realização acontece por meio de filtros digitais sucessivas sobre o sinal original, onde um par de filtros digitais definidos como filtros em quadratura é descrito pelas funções  $h(n)$  e  $g(n)$ , sendo estas, respectivamente, as funções resposta ao impulso de um filtro passa-baixa e passa-alta, cada um com metade da banda do sinal original [15]. Ela é matematicamente definida em  $F_{m,n}(a,b)$ :

$$F_{m,n}(a,b) = a_0^{-j/2} \int f(t)\Psi(a_0^{-j}t - nb_0)$$

#### F. Classificação de Sinais

Como o objetivo do trabalho consiste na análise e classificação de arritmias por meio de *Aprendizado de Máquina*, faz-se necessário realizar a extração das características dos sinais para poder classificar com um certo grau de confiabilidade por meio de algum algoritmo de inteligência artificial.

O primeiro passo necessário para a classificação de sinais se encontra na normalização do sinal de ECG afim de obter e

tratar pedaços de amostras obtidas do sinal. Para realizar esse processo utilizam-se diversos tipos de funções matemáticas, selecionando as amostras filtradas - por janelamento e DWT com extração dos coeficientes, por exemplo - ou através de extração de características diretas do sinal, como o intervalo RR e frequência cardíaca.

### G. Aprendizado de Máquina

O aprendizado de máquina se caracteriza por ser um subcampo dentro de toda a inteligência artificial, e tem o objetivo de desenvolver algoritmos e técnicas que permitam os computadores adquirirem conhecimento sem serem explicitamente programados. Dado um conjunto de amostras cujo tenha classificação conhecida, a máquina consegue interpretar os dados e classificá-los, aprendendo com seus erros [16]. As técnicas do aprendizado de máquina podem ser aplicadas em diversas áreas do conhecimento, como em problemas relacionados a computação, biologia, química e matemática [16].

Os algoritmos de aprendizados de máquinas podem ser divididos em dois principais tipos: os supervisionados e não supervisionados. O aprendizado de máquina supervisionado trata de amostras no qual foram fornecidas uma referência do objetivo, disponibilizando para o computador informações a respeito do ambiente em que as amostras pertencem [17]. Neste tipo de aprendizado, em cada amostra é fornecida variáveis de entrada e a saída esperada, também chamada de *true label*. Ao final do treinamento, é esperado que a máquina seja capaz de fornecer saídas corretas para entradas que nunca foram apresentadas. O aprendizado de máquina não supervisionado não contém o *true label*, tendo amostras compostas apenas pelas variáveis de entrada. Com isso, os algoritmos não supervisionados tentam encontrar padrões nas amostras fornecidas, separando-as em grupos [17].

O cérebro em alguns aspectos possui características similares a um processador. Por exemplo, quando lemos um texto as células fotorreceptoras dos nossos olhos captam um conjunto de símbolos e os transformam em sinais elétricos, que por sua vez, serão processados pelo cérebro para classificá-los em palavras. As redes neurais artificiais (RNAs) consistem em uma metodologia para resolver problemas de inteligência artificial que se espelham em conceitos das redes neurais naturais (RNN). O comportamento de aprendizagem da RNA é igual ao da RNN, ou seja, aprendendo, errando e fazendo descobertas. As unidades de processamento são chamadas neurônios, que são compostos basicamente por dendritos, axônio e corpo celular [18]. A relação entre um neurônio natural e um *Perceptron* ou neurônio booleano foi representada pela Tabela I.

Para classificar o sinal normalizado serão utilizados os algoritmos: *Random Forest* e *Artificial Neural Networks*.

O algoritmo *Random Forest* consiste na criação aleatória de um conjunto de árvores simples de decisão, em que cada uma delas produz uma resposta, dado um conjunto de valores apresentados previamente [19]. Para a classificação de um resultado final, é verificado os resultados independentes de

TABELA I  
RELAÇÃO ENTRE UM NEURÔNIO NATURAL E UM *Perceptron*

<i>Perceptron</i>	Neurônio Natural	Função
Entradas	Dendritos	Recebem o sinal
Saída	Axônio	Saída do sinal
Peso	Sinapse	Retém o Conhecimento

cada árvore gerada, realizando uma votação, em que é elegido o resultado mais votado. A classificação de cada árvore se encontra nos nós folhas de cada árvore criada [20].

O algoritmo de Redes Neurais Artificiais, por sua vez, pode ser definido como técnicas computacionais que apresentam uma estrutura inspirada nas redes neurais de organismos inteligentes, que aprendem a partir de experiências [21]. A estrutura de uma rede neural artificial é composta por unidades interconectadas, que representam os neurônios, em que cada um tem determinado comportamento baseado em suas entradas [22]. Cada neurônio artificial tem entradas que são saídas de outros neurônios. Cada entrada é multiplicada por um peso específico, sendo que esse peso indica sua influência para a saída daquela unidade. Com todos os valores de entradas calculados, é realizada uma soma ponderada, e o valor dessa soma é inserido em uma função para a normalização, gerando o valor de saída daquele neurônio. Chegando ao final da rede neural artificial, é feito o caminho contrário para atualizar os pesos das ligações de cada unidade, também chamado de *backpropagation* [22]. O ciclo de calcular um resultado e atualizar os pesos é denominado como uma época, sendo que para um treinamento de uma rede neural artificial é necessário várias épocas [21].

### III. METODOLOGIA

A partir da proposta e fundamentação teórica apresentada, pode-se determinar quais ferramentas utilizadas e qual metodologia empregada no projeto.

O projeto foi desenvolvido em duas etapas: primeiro o tratamento do sinal para extração de características, e depois o treinamento das arritmias por aprendizado de máquina.

O objetivo do tratamento do sinal foi isolar partes do sinal do ECG por janelamento para, consequentemente, conseguir aplicar *Transformadas Wavelets Discretas* para filtro e redução de ruídos. Através do *software MATLAB*, o janelamento de períodos do sinal foi realizado através de arquivos de anotações da base de dados de arritmia, as quais possuíam exatos períodos de tempo onde a arritmia a ser verificada ocorria.

A partir do sinal normalizado e tratado, realizou-se a extração de duas características cardíacas importantes para posterior treinamento: amplitude da onda R em milivolts (mV) e intervalo de tempo entre ondas R em segundos (seg). Esses dados foram extraídos em arquivos do tipo CSV juntamente com um *true label*, variável a qual caracteriza o tipo de arritmia.

Por fim, com os arquivos contendo as características extraídas dos sinais normalizados, foi possível realizar o apren-



dizado de máquina com o *software* WEKA. Para fim de validação de qual método seria mais eficaz, foi realizado uma comparação entre o treinamento com um algoritmo de Redes Neurais e outro de Árvores de Decisão, utilizando 80% da base de dados como treinamento e 20% como teste.

#### IV. EXTRAÇÃO DE CARACTERÍSTICAS

Conforme apresentado no tópico anterior, a normalização de sinal e extração de características foram realizadas através do *software* MATLAB. Essa etapa foi fundamental para que fosse elaborado um algoritmo modular e completo, capaz de realizar desde o janelamento do sinal até a extração das características para o treinamento com aprendizado de máquina, o qual será detalhado no próximo tópico.

Para uma melhor compreensão desse algoritmo, é necessário compreender o funcionamento da base de dados de arritmia do MIT-BIH. A base conta com 48 amostras de diferentes pessoas, sendo que cada uma das amostras possui uma duração de aproximadamente 30 minutos e com janelas aleatórias de diferentes tipos de arritmias. Para cada amostra é possível realizar a extração de vários tipos de arquivos, onde nesse trabalho três tipos foram focados: extração do sinal com uma faixa (potencial MLII, derivado do tipo V2) em um arquivo .mat, extração de informações do sinal completo em um arquivo .info e, por fim, extração de detalhes de cada período de sinal com os tipos de arritmias - provenientes de considerações de profissionais cardiologistas - em um arquivo .txt. Um exemplo do arquivo de anotações pode ser visualizado através da Figura 9, onde é possível visualizar um tipo de arritmia do tipo Bigeminismo (B no período 0:00.186 ou na amostra 67 do sinal.

Selected input: record mltb/200, annotator atr, from 0:00.000 to 30:05.556
MIT-BIH Arrhythmia Database (mltb)

The output below was prepared using this command:
Annotation key

```
rdm -r mltb/200 -f 0 -t 3005.556 -a atr -v >annotatempo.txt
```

Time	Sample #	Type	Sub Chan	Num	Aux (B)
0:00.186	67	V	1	0	
0:00.625	225	V	1	0	
0:01.353	487	N	0	0	
0:01.914	689	V	1	0	
0:02.678	964	N	0	0	
0:03.186	1147	V	1	0	
0:03.981	1423	N	0	0	
0:04.472	1610	V	1	0	
0:05.228	1882	N	0	0	
0:05.756	2072	V	1	0	
0:06.475	2331	N	0	0	
0:06.961	2586	V	1	0	
0:07.733	2784	N	0	0	
0:08.382	3060	V	1	0	
0:09.107	3266	N	0	0	
0:09.570	3480	V	1	0	
0:10.011	3613	N	0	0	(B)
0:10.383	3730	N	0	0	
0:11.042	3975	N	0	0	
0:11.669	4261	N	0	0	
0:12.167	4410	N	0	0	
0:12.986	4640	N	0	0	
0:13.156	4680	N	0	0	
0:14.261	5134	N	0	0	
0:14.847	5381	N	0	0	
0:15.549	5685	N	0	0	
0:16.169	5821	N	0	0	
0:16.988	6087	N	0	0	
0:17.458	6295	V	1	0	
0:18.186	6547	N	0	0	
0:18.662	6718	V	1	0	
0:19.656	7076	N	0	0	
0:19.167	7368	V	1	0	

Fig. 9. Exemplo de anotações extraídas do sinal ECG 100m dentro do site da Physionet ATM.

Com os 3 arquivos de 17 amostras de sinais foi possível realizar a normalização e extração das 3 arritmias propostas através de 6 etapas realizadas no *MATLAB* para cada uma das 17 amostras:

1. A primeira etapa consistiu em carregar cada um dos 17 sinais de ECG, extraindo os valores elétricos em amplitude e tempo, além da frequência, quantidade de amostras e tempo total do sinal.

2. Em seguida, realizou-se a leitura do arquivo de anotações dos sinais, capturando em um objeto de vetores os períodos e tempos das amostras da arritmia escolhida para extração.

3. Com cada um dos períodos específicos das arritmias, foi possível realizar o janelamento da parte QRS de cada onda, capturando um intervalo de tempo anterior e posterior a amostra de tempo da arritmia extraída na etapa anterior.

4. Após a extração do sinal em amplitude e tempo em um objeto de vetores do janelamento, realiza-se a plotagem de cada sinal QRS extraído, exceto para casos sem arritmia - chamados de *Normal Sinus Rhythm (N)*. Uma extração do janelamento da parte QRS do arquivo 201m pode ser visualizada na Figura 10, onde foi extraída arritmia Trigemismo Ventricular.

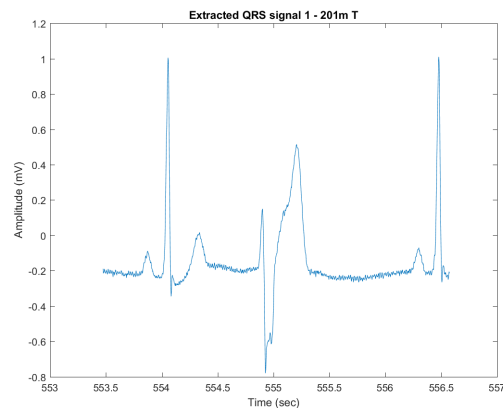


Fig. 10. Sinal QRS de Trigemismo Ventricular extraído por janelamento do arquivo 201m.

5. Com as janelas dos sinais separados em objeto de vetores realiza-se a decomposição de cada sinal janelado em componentes de frequência variantes no tempo com Transformada *Wavelet* Discreta de Sobreposição Máxima (MODWT) e Transformada *Wavelet* Discreta Inversa de Sobreposição Máxima (IMODWT) na escala 3 - funções disponíveis através do *Wavelet Toolbox* do *software* MATLAB.

5. Após a extração do sinal modulado e filtrado com Transformada *Wavelet* Discreta, realizou-se a extração da amplitude e tempo dos picos do sinal janelado através da função **findpeaks** do *Signal Processing Toolbox*.

6. Após a extração dos picos em um objeto de vetores, realiza-se a plotagem de cada sinal com seus respectivos pontos de pico, exceto para casos sem arritmia (N). Uma extração do picos do arquivo 201m pode ser visualizada na Figura 11, onde foi extraída arritmia Trigemismo Ventricular.

7. Por fim, com os dados de amplitude e tempo extraídos em um objeto de vetores, realizou-se a extração de características, capturando o valor de amplitude do último pico do sinal e a diferença de tempo R-R entre o último e o primeiro pico (o pico do meio não se caracteriza como pico R). Após a manipulação desses dados, realiza-se a extração dessas duas características com o tipo da arritmia em um arquivo CSV, populando cada linha do arquivo com cada período de amostra




Fig. 11. Picos de Trigemismo Ventricular extraídos do arquivo 201m.

encontrado para a arritmia escolhida. Um arquivo CSV extraído para o Trigemismo Ventricular pode ser visualizado na Figura 12.

	Amplitude	RR	Arritmia
1	0.999179749489305	2.42222222241594	(T)
2	0.812402861118657	2.52777777779796	(T)
4	0.917963061638229	2.32222222240907	(T)
5	0.751362403333588	2.38888888908002	(T)
6	0.816775909364811	2.45000000019199	(T)
7	0.952208162944667	2.32222222240796	(T)
8	0.850945515633091	2.13333333350408	(T)
9	0.78391964734027	2.19722222239807	(T)
10	0.905538673401304	2.24722222240212	(T)
11	0.88426668630168	2.2305555557341	(T)
12	0.90215857610872	2.31111111129999	(T)

Fig. 12. Arquivo de características extraído para Trigemismo Ventricular referentes ao arquivo 201m.

Essas etapas apresentadas foram executadas para cada um dos 17 arquivos e para todas as arritmias, além do arquivo 100m para extração de características de um sinal saudável (N). Após a extração de todos os CSVs, organizou-se em um só arquivo com todas as características de todos tipos de arritmias, o qual foi repassado para ser inserido no aprendizado de máquina.

## V. TREINAMENTO COM APRENDIZADO DE MÁQUINA

Após a etapa de extração de características, foi obtido um arquivo CSV com 1410 amostras contendo três tipos de arritmia: Bigeminismo Ventricular, Trigemismo Ventricular e Taquicardia Ventricular. Para realizar o treinamento no conjunto de dados obtidos, foi utilizado o *software* WEKA, que disponibiliza diversos algoritmos de inteligência artificial já implementados.

Neste momento, foi necessário a conversão do arquivo CSV com os dados normalizados, para o formato ARFF, para o que o WEKA pudesse executar as leituras das amostras de forma correta. O arquivo ARFF é formado por um cabeçalho, em que é necessário declarar as variáveis que cada amostra irá apresentar, com seu respectivo tipo. As amostras são colocadas logo abaixo, e tem suas variáveis separadas por vírgula, como pode ser visualizado na Figura 13

```
@RELATION all-samples-4types

@ATTRIBUTE Amplitude REAL
@ATTRIBUTE RR REAL
@ATTRIBUTE class {(B,(N,(T,(VT))

@DATA
0.918632070124893,0.8722222222292,(N
1.07035887569268,0.875000000007,(N
1.00747534543356,0.891666666738,(N
1.0243641868242,0.933333333408,(N
0.909587583542613,0.952777777854,(N
0.949626710415752,0.90277777785,(N
```

Fig. 13. Cabeçalho do arquivo ARFF criado.

Com o arquivo ARFF criado, foi necessário carregar o arquivo e escolher o classificador no qual se deseja realizar o treinamento. Para este trabalho foi utilizado dois tipos de classificadores: *Random Forest* e *Artificial Neural Networks*. O resultado do desempenho de cada algoritmo pode ser visualizado nas Figuras 14 e 15.

```
=== Summary ===
Correctly Classified Instances      249      95.3901 %
Incorrectly Classified Instances    13      4.6099 %
Kappa statistic                    0.7328
Mean absolute error                0.0249
Root mean squared error            0.114
Relative absolute error             25.8773 %
Root relative squared error        52.96 %
Total Number of Instances         262

=== Detailed Accuracy By Class ===
```

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	FRC Area	Class
	1,000	0,026	0,611	1,000	0,759	0,772	0,981	0,500	(B)
	0,996	0,179	0,981	0,996	0,988	0,876	0,998	1,000	(N)
	0,417	0,004	0,833	0,417	0,586	0,578	0,981	0,722	(T)
	0,000	0,000	0,000	0,000	0,000	0,000	0,999	0,967	(VT)
Weighted Avg.	0,954	0,162	0,943	0,954	0,943	0,844	0,997	0,968	

```
=== Confusion Matrix ===
a b c d <-- classified as
11 0 0 0 | a = (B)
0 253 1 0 | b = (N)
7 0 5 0 | c = (T)
0 5 0 0 | d = (VT)
```

Fig. 14. Resultados do treinamento com Redes Neurais no *software* WEKA.

```
=== Summary ===
Correctly Classified Instances      277      98.227 %
Incorrectly Classified Instances    5      1.773 %
Kappa statistic                    0.9058
Mean absolute error                0.0153
Root mean squared error            0.089
Relative absolute error             15.8602 %
Root relative squared error        41.3578 %
Total Number of Instances         282

=== Detailed Accuracy By Class ===
```

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	FRC Area	Class
	0,818	0,007	0,818	0,818	0,818	0,811	0,994	0,808	(B)
	0,996	0,000	1,000	0,996	0,998	0,981	1,000	1,000	(N)
	0,833	0,007	0,833	0,833	0,833	0,826	0,994	0,855	(T)
	1,000	0,004	0,833	1,000	0,909	0,911	1,000	1,000	(VT)
Weighted Avg.	0,982	0,001	0,983	0,982	0,982	0,966	0,999	0,986	

```
=== Confusion Matrix ===
a b c d <-- classified as
9 0 2 0 | a = (B)
0 253 0 1 | b = (N)
2 0 10 0 | c = (T)
0 0 0 5 | d = (VT)
```

Fig. 15. Resultados do treinamento com Árvore de Decisão no *software* WEKA.

## VI. RESULTADOS E DISCUSSÕES

A partir dos resultados obtidos com o aprendizado de máquina, foi possível analisar a eficiência do método de extração de características e dos algoritmos de aprendizado na área de ECG.

Conforme pode ser visualizado nos resultados do treinamento com Redes Neurais - representado pela Figura 14 - a arritmia do tipo Bigeminismo Ventricular e os casos normais (sem arritmia) foram classificadas com eficiência nos testes, enquanto as arritmias do tipo Trigemínismo e Taquicardia Ventricular não foram classificadas adequadamente. Com esses resultados, algumas considerações podem ser feitas: o método de normalização e extração de características pelo *software MATLAB* foi extremamente eficiente no caso do Bigeminismo e do tipo Normal, demonstrando que precisa ser aprimorado para extração das características dos outros dois tipos de arritmia; a outra consideração pode estar presente na quantidade de características extraídas, as quais podem não ter sido suficientes para classificação dos tipos Trigemínismo e Taquicardia Ventricular.

Em contraposição, os resultados do treinamento com Árvores de Decisão - representado pela Figura 15 - demonstram um treinamento e teste eficiente, com classificação correta de cada tipo de arritmia, onde os casos de Bigeminismo e Trigemínismo Ventricular apresentam apenas duas classificações erradas nos testes.

A partir dos resultados de acurácia apresentados através da Tabela II, foi possível verificar que, com as características extraídas para testes de ECG, o aprendizado de máquina utilizando o algoritmo de Árvores de Decisão *Random Forest* apresentou-se como mais adequado para utilização, com pior caso para Bigeminismo com 81,8%. Os resultados apresentados provavelmente poderiam ser melhores se fossem realizados com uma maior quantidade de amostras tanto para treinamento quanto para teste.

TABELA II  
RESULTADOS DE ACURÁCIA PARA APRENDIZADO DE MÁQUINA  
UTILIZANDO REDE NEURAL E ÁRVORES DE DECISÃO

Tipo de Arritmia	Redes Neurais	Random Forest
(B)	100%	81,8%
(N)	99,6%	99,6%
(T)	41,7%	83,3%
(VT)	0%	100%

## VII. CONCLUSÃO

### Precisa melhorar a conclusão.

Como apresentado anteriormente, o objetivo desse trabalho é realizar não apenas a conexão entre dois módulos de rádio frequência, mas principalmente realizar a análise dos pacotes e dados enviados, verificando possíveis erros e perdas. Nesse quesito, o projeto deve apresentar, em sua entrega e apresentação, a transmissão de pacotes de dados em tempo real e a geração de gráficos e dados estatísticos que possam ilustrar

a situação real dessa transferência sob diferentes aspectos do meio.

Caso seja possível, o projeto também pode visar o tratamento desses dados diretamente nos atuadores, visualizando possíveis situações que possam corrigir e inibir erros e atenuações que influenciam e impedem o tráfego dos dados da melhor maneira possível.

## REFERÊNCIAS

- [1] G. F. Barata, "A primeira década da aids no brasil: O fantástico apresenta a doença ao público," Dissertação, Faculdade de Filosofia, Letras e Ciências Humanas da Universidade de São Paulo, 2006.
- [2] T. W. Pogge, "Human rights and global health: A research program," *META*, vol. 36, no. 1/2, pp. 26–1068, January 2005. [Online]. Available: [https://www.researchgate.net/profile/Thomas\\_Pogge/publication/227624773\\_Human\\_Rights\\_and\\_Global\\_Health\\_A\\_Research\\_Programme/links/02e7e523377151c275000000/Human-Rights-and-Global-Health-A-Research-Programme.pdf](https://www.researchgate.net/profile/Thomas_Pogge/publication/227624773_Human_Rights_and_Global_Health_A_Research_Programme/links/02e7e523377151c275000000/Human-Rights-and-Global-Health-A-Research-Programme.pdf)
- [3] W. H. Federation, "World heart federation 2002 annual report," Report, 2002. [Online]. Available: [http://www.world-heart-federation.org/fileadmin/user\\_upload/documents/About-annual-report-2002.pdf](http://www.world-heart-federation.org/fileadmin/user_upload/documents/About-annual-report-2002.pdf)
- [4] A. B. Neto, "Detecção automática de arritmia cardíaca utilizando wavelet e redes neurais treinadas com otimização por nuvem de partículas," Master Thesis, Pós-Graduação em Informática da Pontifícia Universidade Católica do Paraná - Curitiba, 2009. [Online]. Available: [https://www.ppgia.pucpr.br/pt/arquivos/mestrado/dissertacoes/2009/2009\\_alfredo\\_beckert.pdf](https://www.ppgia.pucpr.br/pt/arquivos/mestrado/dissertacoes/2009/2009_alfredo_beckert.pdf)
- [5] L. National Heart and B. Institute, "Anatomy of heart," Novembro 2011. [Online]. Available: <https://www.nlm.nih.gov/health/health-topics/topics/hhw/anatomy>
- [6] H. Gray, *Anatomia*, ser. 35. Ed. Guanabara Koogan, 1979, vol. 2.
- [7] A. C. G. J. E. Hall, "Textbook of medical physiology," Textbook, 2006.
- [8] M. de Mello Aires, *Fisiologia*. Guanabara Koogan S.A., 1991.
- [9] S. B. de Cardiologia, "Diretriz de fibrilação atrial," in *Arq Bras Cardiologia*, ser. Suplemento VI, 2003, vol. 81.
- [10] M. A. B. Gonçalves, *Noções Básicas de Eletrocardiograma e Arritmias*. Senac, 1995.
- [11] Wanderer, "Ventricular bi & trigeminy," Online Article, February 2009. [Online]. Available: <https://lostonthefloor.wordpress.com/2009/02/23/ventricular-bi-trigeminy/>
- [12] N. Instruments, "Ffts e janelamento (windowing)," Online, October 2016. [Online]. Available: <http://www.ni.com/white-paper/4844/pt/>
- [13] A. Graps, *An Introduction to Wavelets*. IEEE Computational Science and Engineering, 1995, vol. 2, no. 2.
- [14] C. Y. V. W. da Silva, "Extração de características de imagens médicas utilizando wavelets para mineração de imagens e auxílio ao diagnóstico," Master's thesis, Instituto de Ciências Matemáticas e de Computação - USP, 2006. [Online]. Available: <http://www.teses.usp.br/teses/disponiveis/55/55134/tde-07052008-102458/pt-br.php>
- [15] C. R. Castelano, "Estudo comparativo da transformada wavelet no reconhecimento de padrões da íris humana," Master's thesis, Escola de Engenharia de São Carlos - USP, 2006. [Online]. Available: <http://www.teses.usp.br/teses/disponiveis/18/18133/tde-30112006-134736/pt-br.php>
- [16] L. Morellato, "Aprendizado de máquina aplicado à web," Online Article, July 2008. [Online]. Available: <https://imasters.com.br/artigo/9413/tecnologia/aprendizado-de-maquina-aplicado-a-web/?trace=1519021197&source=single>
- [17] B. Marr, "Supervised v unsupervised machine learning - what's the difference?" Online Article, March 2017. [Online]. Available: <https://www.forbes.com/sites/bernardmarr/2017/03/16/supervised-v-unsupervised-machine-learning-whats-the-difference/#59115eb5485d>
- [18] Z. L. Kovács, *Redes Neurais Artificiais*, 2nd ed., C. Cognition, Ed. Livraria da Física, 1996.
- [19] Statsoft, "Random forests," Online Article, September 2009. [Online]. Available: <http://www.statsoft.com/Textbook/Random-Forest>
- [20] G. V. Dantas, "Utilização de classificador random forest na detecção de falhas em máquinas rotativas," August 2015. [Online]. Available: <http://monografias.poli.ufjf.br/monografias/monopoli10015019.pdf>
- [21] A. P. de Leon F. de Carvalho, "Redes neurais artificiais," Online Article, June 2009. [Online]. Available: <http://conteudo.icmc.usp.br/pessoas/andre/research/neural/>



- [22] F. J. V. Z. Leandro N. de Castro, "Redes neurais artificiais," Online Article, April 2003. [Online]. Available: [ftp://ftp.dca.fee.unicamp.br/pub/docs/vonzuben/ia006\\_03/topico5\\_03.pdf](ftp://ftp.dca.fee.unicamp.br/pub/docs/vonzuben/ia006_03/topico5_03.pdf)